



SQLDAY LITE 2026

Kompendium uczestnika

Od pytania do agenta · warsztat Databricks



Krzysztof Burejza · Mariusz Wiecha

23 września 2026

Spis treści

1	Od pytania do agenta	Jak korzystać
2	Model, tokeny i kontekst	Co model dostaje w jednym wywołaniu?
3	Workflow, agent i narzędzie	Tool calling nie wykonuje funkcji samodzielnie
4	RAG i embeddingi	Dlaczego liczby pomagają szukać?
5	Chunking i wyszukiwanie	Cytat to punkt rozpoczęcia kontroli
6	Dane i uprawnienia	Kto wykonuje operację?
7	Trace, testy i ewaluacja	
8	Koszt i wybór architektury	Jeden agent czy supervisor?
9	MCP: wspólny protokół narzędzi	
10	Bezpieczeństwo i granice działania	
11	Co zbudowaliśmy na warsztacie	
12	Ściąga decyzji i diagnozy	Gdzie szukać błędu Przed kolejną iteracją
13	Źródła i dalsza nauka	Materiały lokalne

Od pytania do agenta. Kompendium uczestnika

Teoria, wizualna ściągą i podsumowanie warsztatu. SQLDay Lite 2026.

Od pytania do agenta

Kompendium uczestnika | SQLDay Lite 2026

Teoria, wizualna ściągą i podsumowanie warsztatu Databricks. Do czytania przed ćwiczeniem i do szybkiego sprawdzenia pojęcia, gdy budujesz własne rozwiązanie.



Rozmowa
Ogólna wiedza



RAG
Wyszukanie źródła



Agent
Wybór narzędzi

Jak korzystać

Strony 2-10 wyjaśniają mechanizmy. Strona 11 przypomina, co powstało w każdym module. Strona 12 pomaga wybrać następny krok. Na stronie 13 znajdziesz dokumentację źródłową.


Szukasz odpowiedzi na pytanie	Strona
Co model wie i co mieści się w kontekście?	2
Kiedy workflow, kiedy agent i jak działa narzędzie?	3
Jak działa RAG i od czego zależy trafność?	4-5
Jak liczyć dane i kontrolować dostęp?	6
Jak mierzyć jakość, koszt i ryzyko?	7-8, 10
Co zmienia MCP?	9

Pytanie biznesowe wyznacza źródła, narzędzia i testy.

Model, tokeny i kontekst

M1 | Dlaczego płynna odpowiedź może być błędna

LLM generuje kolejne tokeny na podstawie dostępnego kontekstu. **Token** to jednostka tekstu używana przez model; nie musi odpowiadać całemu słowu. Model wylicza rozkład następnego tokenu, a algorytm generowania wybiera token i dopisuje go do sekwencji.



Co model dostaje w jednym wywołaniu?

Instrukcje, pytanie, przekazaną historię oraz dołączone wyniki narzędzi i fragmenty źródeł. Sam fakt istnienia tabeli w workspace nie udostępnia jej modelowi. **System prompt** opisuje zadanie, zasady i sposób odmowy; nie nadaje uprawnień do danych.

Pojęcie	Znaczenie praktyczne
Okno kontekstu	Limit tokenów dla wywołania. Uwzględnij wejście i miejsce na odpowiedź; sprawdź także osobny limit wyjścia.
Temperatura	Wpływa na rozkład używany przy losowaniu. Nie jest suwakiem prawdziwości; ustawienie 0 nie gwarantuje identycznych wyników usługi.
Halucynacja	Treść bez oparcia w dostępnych faktach, nawet jeśli brzmi przekonująco.


W M1 porównujesz te same pytania bez system promptu i z nim. Zmiana stylu nie dowodzi poprawności faktów.

Źródła [1], [2]. Warsztat: m1-ask, m1-four-questions, m1-playground-lab.

Workflow, agent i narzędzie

M2 i M5 | Kto wybiera następny krok

Workflow wykonuje kroki ustalone w kodzie. **Agent** używa modelu do wyboru następnego działania na podstawie pytania i dotychczasowych wyników. RAG może być stałym workflow albo jednym z narzędzi agenta. Chatbot opisuje formę rozmowy, więc również może korzystać z RAG i narzędzi.



Tool calling nie wykonuje funkcji samodzielnie

Model zwraca nazwę narzędzia oraz argumenty. Aplikacja sprawdza wywołanie, uruchamia kod i przekazuje wynik do modelu. Dopiero ten wynik może stać się podstawą odpowiedzi.

Część kontraktu	Co ustalasz
Nazwa i opis	Co narzędzie robi, kiedy je wybrać, kiedy nie.
Argumenty	Typy, dopuszczalne wartości i walidacja.
Wynik i błędy	Pola potrzebne do odpowiedzi; osobno brak danych i błąd.
Dostęp	Tożsamość wykonawcza oraz prawa do odczytu lub zapisu.


Zła trasa może wynikać z opisu, promptu, nakładających się narzędzi lub modelu. Najpierw znajdź decyzję w trasie.

Źródło [3]. Warsztat: m2-payload-test; m5-build-agent-run. Limit `recursion_limit = 12` w M5 nie oznacza 12 wywołań modelu: jedna tura agenta to dwa węzły grafu (model i narzędzie), więc 12 daje sześć tur.

RAG i embeddingi

M3 | Wiedza dołączona do pytania

RAG to pobranie danych wspierających odpowiedź i dołączenie ich do wejścia modelu. W warsztacie źródłem są raporty PDF. Model odpowiedzi nie jest przy tym trenowany. **Fine-tuning** aktualizuje wagi na przykładach; te dwie metody mogą się uzupełniać.



Dlaczego liczby pomagają szukać?

Embedding to wektor reprezentujący tekst. Odległość lub podobieństwo wektorów pomaga uszeregować kandydatów związanych z pytaniem. W lokalnym wariancie notebooka normalizacja i iloczyn skalarny dają podobieństwo kosinusowe. Inne systemy mogą używać innych miar.

Przygotowanie źródeł	Odpowiedź na pytanie
PDF, tekst i metadane	Pytanie i ewentualny filtr
Fragmenty i ich embeddingi	Wyszukanie kandydatów
Indeks do wyszukiwania	Kontekst, model i odpowiedź ze źródłem

Ważne: model embeddingowy może być inny niż model piszący odpowiedź. Pytania i dokumenty muszą jednak używać zgodnej przestrzeni embeddingów.

Bliskość wektorów nie dowodzi prawdziwości ani przydatności fragmentu. Przeczytaj znalezione źródło.

Źródła [4], [5]. Warsztat: m3-embedding, m3-retrievers, m3-custom-rag.

Chunking i wyszukiwanie

M3 | Jak dostarczyć modelowi właściwy fragment


Chunking dzieli dokument na fragmenty. **Overlap** powtarza część treści na granicy fragmentów. Celem jest zachowanie sensu, np. warunku, nagłówka lub związku między wierszami tabeli. Samo zwiększanie fragmentu nie zapewnia lepszego wyniku.

Utracony warunek



Brak kontekstu zmienia znaczenie zdania.

Zachowany kontekst



Warunek pozostaje częścią informacji.

Przykład dydaktyczny

Ustawienie	Co warto sprawdzić
Rodzaje	Stały rozmiar (co N znaków), rekurencyjny (separatory po kolei: strona, akapit, zdanie; nasz domyślny), po strukturze dokumentu (nagłówki, strony, tabele), zdaniowy/semantyczny (granica tam, gdzie zmienia się temat), bez chunkingu (krótkie teksty, jak opinie w M3 · B), parent-child (szukaj po małym fragmencie, odpowiadaj z całej sekcji). Tabela w m3-chunking-intro .
Rozmiar i nakładka	W labie 600/100, 2000/0 i 300/50 oznaczają znaki, nie tokeny. Sprawdź też limit modelu embeddingowego.
ANN	Podobieństwo wektorów; przydatne do parafraz.
FULL_TEXT / HYBRID	Słowa kluczowe albo połączenie ich z wyszukiwaniem wektorowym. Porównaj na nazwach i identyfikatorach.
k oraz filtr	k ogranicza liczbę zwróconych wyników; filtr zawęża zbiór kandydatów. Większe k zajmuje więcej kontekstu.

Cytat to punkt rozpoczęcia kontroli

Sprawdź, czy **doc_id** i **chunk_id** wskazują istniejące źródło, czy fragment uzasadnia tezę i czy nie pominięto warunku. Oddziel ocenę wyszukiwania od oceny odpowiedzi modelu.

Eksperyment ze splitterem w pamięci nie przebudowuje automatycznie indeksu. Porównuj warianty na tym samym zestawie pytań.

Źródło [5]. Warsztat: m3-chunking-lab, m3-chunking, m3-path-c. Obsługa zbyt długiego wejścia zależy od modelu i API.

Dane i uprawnienia

M4 | Najpierw definicja miary, potem wynik

Sposób dostępu	Kiedy pasuje
SQL	Masz zapytanie referencyjne i jawną definicję miary.
Funkcja Unity Catalog	Znany przypadek biznesowy, kontrolowane argumenty i wynik.
Genie	Pytania ad hoc. Sprawdzasz wygenerowany SQL i założenia.

Snapshot warsztatu ma **28 813 wierszy** i **28 670 unikalnych klientów**. Dla segmentu VIP filtr `loyalty_segment = 3` daje 9 541 wierszy, ale 9 494 różne `customer_id`. `COUNT(*)` i `COUNT(DISTINCT customer_id)` odpowiadają na różne pytania.

Maska kolumny

id	region	tax_id
1	PL	***
2	DE	***
3	PL	***

Filtr wierszy

id	region	tax_id
1	PL	***
3	PL	***
2	DE	***



Maska zmienia widoczną wartość. **Filtr** ogranicza rekordy.

Kto wykonuje operację?

Least privilege oznacza minimalne potrzebne uprawnienia. Dla SQL UDF wywołujący potrzebuje `EXECUTE` oraz `USE CATALOG` i `USE SCHEMA`. Wewnątrz funkcji dostęp do tabel jest sprawdzany względem właściciela funkcji. Dlatego treść i właściciel funkcji są częścią kontroli dostępu.

Polityki danych testuj pod docelową tożsamością. Po zmianie definicji funkcji sprawdź `SHOW GRANTS`; lokalny test w repo wykazał utratę grantów po `CREATE OR REPLACE`.


W m4-cleanup zdejmujesz filtr i maskę ćwiczenia przed M5. Nie traktuj ich potem jako aktywnej ochrony agenta.

Źródło [6]. Dane: notebook M4. Bez zmian danych i kodu funkcja jest powtarzalna; wynik może się zmienić po zmianie snapshotu.

Trace, testy i ewaluacja

M5 | Dobra trasa to dopiero część sukcesu

Trace rejestruje przebieg aplikacji: wywołania, argumenty, wyniki, czas i dostępne dane o tokenach. **Span** jest pojedynczą operacją w tym przebiegu. Trace nie jest zapisem prywatnego toku rozumowania modelu.



Warstwa oceny	Pytanie kontrolne
Trasa	Czy agent użył właściwych narzędzi i argumentów?
Treść	Czy odpowiedź jest poprawna, kompletna i wsparta źródłem?
Bezpieczeństwo	Czy wynik nie ujawnia niedozwolonych danych i działań?
Koszt i czas	Czy liczba wywołań, tokenów i opóźnienie są akceptowalne?

Macierz tras przypisuje pytaniom oczekiwane narzędzia lub brak wywołań. W M5 porównujemy zbiory nazw. Taki test nie wykryje wszystkich powtórzeń ani błędnej kolejności. Sprawdź je w trace. Regex `tax_id` wykrywa tylko określony wzorec, nie wszystkie dane wrażliwe.


Scorer ocenia wynik według kryterium. Sędzia LLM jest jednym z wariantów scorera; wymaga rubryki i kontroli na przykładach ocenionych przez człowieka.

Testuj trasę i treść. Zmieniaj jedną rzecz, powtarzaj te same pytania i sprawdzaj regresje.

Źródło [7]. Warsztat: m5-route-run, m5-repair, m5-path-c. Próg 2 z 3 tras w capstone jest dydaktyczny, nie produkcyjny.

Koszt i wybór architektury

M5 | Mierz cały przebieg pytania



Koszt modelu = suma tokenów wejścia / 1 000 000 × stawka wejścia + suma tokenów wyjścia / 1 000 000 × stawka wyjścia. Dla różnych modeli liczą składniki osobno.

Przykład dydaktyczny	Wynik
2 000 tokenów wejścia × 2 USD / mln	0,004 USD
500 tokenów wyjścia × 8 USD / mln	0,004 USD
Razem na pytanie	0,008 USD
100 osób × 20 pytań × 22 dni	44 000 pytań; 352 USD za model

To fikcyjne stawki i zużycie, nie cennik. Osobno uwzględnij compute, wyszukiwanie i inne usługi. Brak token_usage w trace nie oznacza zerowego kosztu. W m5-cost pola cenowe 0.0 czekają na uzupełnienie.

Jeden agent czy supervisor?

Jeden agent wybiera funkcje lub wyszukiwanie. Supervisor wybiera subagenta, który może mieć własną pętlę. Taki podział pomaga, gdy istnieją osobne specjalizacje lub zespoły. Dokłada jednak wywołania i kolejne miejsca do diagnozy błędów.


Limit iteracji ogranicza pętlę, nie jest dokładnym limitem kosztu. Porównuj jakość, opóźnienie i koszt na własnych trace'ach.

Warsztat: m5-cost, m5-single-vs-multi. AI Search może zużywać zasoby także bez zapytań; sprawdź tryb endpointu i warunki rozliczeń.

MCP: wspólny protokół narzędzi

M6 | Odkrycie narzędzia, wywołanie, wynik

Model Context Protocol standaryzuje komunikację aplikacji z serwerem udostępniającym narzędzia. Hostem jest aplikacja; klient MCP utrzymuje połączenie z serwerem. list_tools odkrywa opisy, a call_tool wywołuje wybrane narzędzie.



W warsztacie	Co się zmienia
Zarządzany MCP	Dostęp do funkcji UC, AI Search lub Genie w workspace.
Usługa system.ai.*	Dostęp do narzędzi usług zewnętrznych przez Unity Gateway. Dla wybranych dostawców każdy użytkownik loguje się przez OAuth.
Odczyt i zapis	Tworzenie nowego pliku, nadpisanie i usunięcie mają różne skutki. Sprawdź argumenty i zakres konta.

readOnlyHint i **destructiveHint** to wskazówki opisujące narzędzie, nie uprawnienia. Obecność funkcji na liście nie dowodzi, że polityka pozwoli ją wykonać. Wbudowane usługi mogą blokować operacje zapisu.


Pokaz M6 tworzący dokumenty to gotowe wywołania tools/call z przygotowaną treścią. Kod jest w demo/, a uczestnik ma opis w labs/.

Źródła [8], [9]. Warsztat: m6-mcp-client, m6-external, m6-ceo-report (finał: raport dla CEO). Demo system.ai.* przygotowano na Premium.

Bezpieczeństwo i granice działania

M6 | Odmowa modelu to obserwacja, nie gwarancja

Prompt injection to próba wpłynięcia na zachowanie aplikacji przez instrukcje w danych wejściowych, np. w pobranym raporcie. **Jailbreak** próbuje obejść zasady modelu. Dokument źródłowy pozostaje danymi, nawet gdy zawiera polecenie.



Próba z m6-attacks	Czego szukasz w wyniku
Fikcyjna historia o wycieku	Czy model odmawia i czy narzędzia w ogóle udostępniają żądane dane?
Prośba o tax_id	Czy funkcja ogranicza wynik; czy kontrola danych działa pod właściwym kontem?
Sprzedaż w Kanadzie	Czy agent przyznaje brak danych zamiast podawać zero?
Usunięcie klienta	Czy istnieje narzędzie zapisujące i czy konto ma prawo je wykonać?

Ochronę budują wspólnie: ograniczony zakres narzędzi, walidacja argumentów, uprawnienia, polityki danych, kontrola wyników i testy. Prompt określa zachowanie, ale nie zastępuje tych mechanizmów. Trace pomaga odtworzyć przebieg, a audyt służy badaniu zdarzeń i tożsamości.


Dla każdej próby zapisz wynik, dowód i ograniczenie testu. Błąd usługi nie dowodzi, że atak został zatrzymany właściwą kontrolą.

Warsztat: m6-attacks, m6-least-privilege. Maska ćwiczenia M4 została zdjęta; nie zakładaj jej obecności w M6.

Co zbudowaliśmy na warsztacie

M0-M6 | Mapa rezultatów do odtworzenia

Historia TechRetail łączy pytania o liczby z pytaniami o raporty. Agent M5 ma trzy funkcje Unity Catalog i narzędzie `search_retail_reports`. Genie z M4 jest osobnym sposobem pracy z tabelą, nie piątym narzędziem tego agenta.



Moduł	Co masz na koniec	Gdzie wrócić
M0	Dane, preflight i Canvas	00_setup/00_setup
M1	Odpowiedzi bazowe i prompt	labs/m1_agentic_ai_playground
M2	Trzy funkcje i test payloadu	labs/m2_tool_calling
M3	RAG, cytaty i test braku źródła	labs/m3_rag_ai_search
M4	Definicja miary i test polityk	labs/m4_sql_genie_governance
M5	Sześć tras, trace, poprawka i koszt	labs/m5_end_to_end_agent
M5+	Wzorzec na Bakehouse lub Airbnb	labs/m5b_transfer_capstone
M6	MCP i cztery próby ataków	labs/m6_mcp_security_next_steps

Ścieżki plików są względne wobec workshop/. Każdy notebook ma trzy ścieżki pracy: A · Razem (TechRetail, z prowadzącym), B · Samodzielnie (ten sam wzorzec na Bakehouse) i C · Wyzwanie. Rozwiązania wszystkich trzech leżą w demo/. Przykłady referencyjne na innych danych są w pattern/, a Canvas i szkielety multiagent oraz CI/CD w transfer/.

Capstone: dwa narzędzia, trzy przypadki testowe i opis ograniczenia. Wynik 2/3 to punkt kontrolny nauki, nie certyfikat jakości.

Źródło: bieżące notebooki demo/ i labs/. Capstone domyślnie szuka tekstów po słowach; AI Search jest opcją.

Ściąga decyzji i diagnozy

Do wykorzystania we własnym projekcie

Jeśli potrzebujesz...	Zacznij od...
Przekształcić tekst już podany w pytaniu	Promptu i testu poprawności wyniku.
Wiedzy z aktualnych dokumentów	RAG z kontrolą źródeł i daty danych.
Policzyć znaną miarę	SQL-a lub wąskiej funkcji UC.
Wybierać między różnymi źródłami	Agenta i macierzy oczekiwanych tras.
Wykonać stałą sekwencję kroków	Workflow z jawną obsługą błędów.
Połączyć wyspecjalizowane agenty	Supervisora, gdy podział ma uzasadnienie.

Gdzie szukać błędu

Objaw	Pierwsze sprawdzenie
Zły dokument	Zapytanie, embeddingi, filtr, fragmenty, aktualność indeksu.
Dobre źródło, zła odpowiedź	Warunki w kontekście, prompt i kryteria oceny treści.
Niewłaściwe narzędzie	Opis, argumenty, nakładanie kompetencji i decyzja w trace.
Powtarzane wywołania	Kolejność kroków, błędy narzędzia, limit iteracji.
Odmowa dostępu	Konto wykonawcze, konkretny obiekt i jego granty.
Brak indeksu	retrieve_local w M3/M5; nadal potrzebne są modele.

Przed kolejną iteracją

Zapisz pytanie użytkownika, oczekiwane źródło, dopuszczalne działanie i dowód sukcesu. Zmień jeden element. Powtórz testy tras, treści i bezpieczeństwa. Porównaj czas oraz koszt. Zanotuj, czego nadal nie sprawdziłeś.

Po warsztacie uzupełnij Canvas i wybierz jeden brakujący test. Następnie porównaj rozwiązanie z demo/, zamiast kopiować cały projekt bez sprawdzenia.

Źródła i dalsza nauka

Dokumentacja, notebooki i pochodzenie ilustracji

Opracowanie odpowiada wersji materiałów sprawdzonej 21.09.2026. Mechanizmy wyjaśniono niezależnie od szczegółów interfejsu. Dostępność funkcji, limity usług i ceny sprawdzaj w aktualnej dokumentacji.

[1] Generowanie tokenów [Hugging Face · Generation strategies](#)

[2] Okno kontekstu [Anthropic · Context windows](#)

[3] Workflow i agenci [Anthropic · Building effective agents](#)

[4] Retrieval-augmented generation [Databricks · RAG](#)

[5] Embeddingi i wyszukiwanie [Databricks · AI Search](#)

[6] Uprawnienia SQL UDF [Microsoft Learn · Authorized user and session user](#)

[7] Ocena zapisanych przebiegów [MLflow · Evaluating traces](#)

[8] Usługi MCP [Databricks · Built-in MCP Services](#)

[9] Znaczenie adnotacji narzędzi [Model Context Protocol · Tool annotations](#)

Materiały lokalne

documents/scripts/dokumentacja_i_linki.md zawiera szerszy spis odsyłaczy. Limity środowiska:

documents/scripts/cheat_sheet_free_vs_premium.md. Szczegółowy przebieg ćwiczeń:

Podrecznik_uczestnika.pdf (przejście przez notebooki) oraz notebooki labs/ i demo/.

Diagramy pochodzą z prezentacji "Od pytania do agenta - SQLDay Lite 2026". Są autorskimi wizualizacjami AI inspirowanymi stylem Databricks, nie oficjalnymi schematami producenta. Dane liczbowe TechRetail dotyczą snapshotu warsztatowego; rachunek kosztu na stronie 8 jest przykładem.