
1. Wstęp

Dokument podsumowuje cztery moduły szkoleniowe przygotowane w środowisku Databricks: `rag_agent`, `single_agent_app`, `genai_eval_and_monitor` oraz `genai_deploy_and_monitor`. Materiały, notebooki, dane testowe i instrukcje zostały wygenerowane przez AI na podstawie celów dydaktycznych kursów Databricks, a nie przepisane z ich materiałów źródłowych.

Zakres obejmuje pełny przepływ od dokumentów i RAG, przez pojedynczego agenta z narzędziami Unity Catalog, po guardrails, ewaluację, batch inference, wdrażanie oraz monitoring. Raport rozdziela etapy zweryfikowane w Databricks Free Edition od etapów przygotowanych, lecz zablokowanych ograniczeniami Model Serving, AI Gateway lub dostępnych endpointów.

Cztery moduły tworzą jeden ciąg praktycznych ćwiczeń: `rag_agent` buduje RAG na dokumentach, `single_agent_app` pokazuje agenta pracującego z funkcjami Unity Catalog, `genai_eval_and_monitor` dodaje guardrails i ewaluację, a `genai_deploy_and_monitor` opisuje batch scoring, wdrożenie oraz monitoring. Zestaw zawiera dane testowe, notebooki, instrukcje i odtwarzalne raporty.

Największym ograniczeniem okazała się rozbieżność między materiałami kursowymi a możliwościami Databricks Free Edition: zmienna dostępność modeli, limit endpointów, brak możliwości utworzenia części endpointów oraz brak external storage wymaganego przez AI Gateway. Z tego powodu raport nie przedstawia niezwyfikowanych etapów jako działających. Największą wartością materiałów jest przejrzyste pokazanie pełnych przepływów oraz rzeczywistych wymagań platformy, wraz z rozróżnieniem kodu, konfiguracji UI i ograniczeń środowiska.

2. rag_agent

Wstęp

Moduł jest inspirowany kursem „Building Retrieval Agents On Databricks”. Pokazuje drogę od testowych dokumentów PDF do systemu RAG, który wyszukuje fragmenty materiałów i używa ich jako kontekstu odpowiedzi. Moduł oraz instrukcja zostały zweryfikowane 22.07.2026.

Notebooki

- 01_parse_robotics_documents — parsowanie dziesięciu testowych PDF-ów przez Python i SQL z `ai_parse_document`, zapis Pythonowego wyniku do Delta, metadane oraz wizualizacja dokumentu.
- 02_chunking — konwersja sparsowanego JSON do Markdown i zwykłego tekstu, chunking LangChain oraz zapis chunków do Delta.
- 03_vector_search — embeddingi, Change Data Feed, indeks AI Search Delta Sync oraz semantic, hybrid, full-text i filtrowane wyszukiwanie.
- 04_building_and_logging — AI Playground, agent LangChain oparty na AI Search, MLflow tracing oraz rejestracja modelu w Unity Catalog.
- 05_building_assistant — wczytanie PDF-ów z Volume i instrukcja utworzenia Knowledge Assistant oraz Examples / Guidelines w UI.

Ograniczenia

- Reranking z ostatniego bloku notebooka 03 nie był dostępny w Free Edition bez dodatkowej konfiguracji workspace.
- Dostępność AI Search, Knowledge Assistant i modeli zależy od regionu oraz workspace. GPT zwracały timeouty, a Inkling był dostępny tylko przez krótki czas, po czym przestał być widoczny.
- Knowledge Assistant nie został potwierdzony end-to-end w Free Edition, mimo że instrukcja UI i źródło Volume zostały przygotowane.

Wnioski

Przygotowano dziesięć fikcyjnych artykułów o robotyce. Każdy zawiera mockowy tekst edukacyjny, ilustrację, tabelę porównawczą i wykres z fikcyjnymi danymi, dzięki czemu nadaje się do testowania parsowania. Materiały kursu „Building Retrieval Agents On Databricks” były praktyczne i dobrze uzasadniały kolejne kroki, na przykład zasady tworzenia promptów. Najwięcej problemów wynikało z konfiguracji usług zależnych od workspace, a nie z samego przepływu RAG.

3. single_agent_app

Wstęp

Moduł jest inspirowany kursem „Building Single-Agent Applications on Databricks”. Zamiast indeksu dokumentów wykorzystuje tabelę Delta z ofertami Airbnb w San Francisco oraz funkcje Unity Catalog, które agent może wywoływać jako narzędzia. Moduł i instrukcja zostały zweryfikowane 23.07.2026.

Notebooki

- 06_building_uc_functions — wczytanie pliku Airbnb CSV do Delta table, funkcje SQL i Python, testy ich działania oraz rejestracja funkcji w Unity Catalog.
- 07_building_agent — agent LangChain z Unity Catalog Function Toolkit, konfiguracją JSON, endpointem databricks-meta-llama-3-3-70b-instruct i MLflow tracingiem.
- 08_mlflow_tracing — lokalizacja eksperymentów MLflow, artefakty, testowe wywołanie agenta, eksploracja trace’ów oraz trace decorator.
- 09_tagging — tagowanie trace’ów, walidacja promptów, eksport agenta, zapis modelu pyfunc i rejestracja modelu w Unity Catalog.

Ograniczenia

Podstawowy przepływ modułu został wykonany w Free Edition. Nie wystąpiły trwałe blokady limitów, ponieważ scenariusz nie wymagał AI Search ani wielu synchronizowanych usług. Występowały natomiast przejściowe problemy zgodności LangChain i LangGraph, które wymagały aktualizacji kodu oraz właściwego doboru zależności.

Wnioski

Pobrany CSV Airbnb zapewnił prosty i realistyczny kontekst dla funkcji Unity Catalog oraz agenta. W tym module dostępny był model databricks-meta-llama-3-3-70b-instruct. Tworzenie notebooków było prostsze niż w rag_agent, a Codex lepiej niż Genie sprawdzał się w diagnozowaniu błędów zależności i naprawie kodu. Materiały teoretyczne kursu były jednak mało przystępne: zawierały dużo buzzwordów i nazw własnych, a część treści niewiele pomagała osobie bez wcześniejszej znajomości Databricks i agentów AI.

4. genai_eval_and_monitor

Wstęp

Moduł jest inspirowany kursem „Generative AI Application Evaluation and Governance”. Rozszerza wcześniejsze ćwiczenia o dane z Marketplace, guardrails, benchmarkowanie, klasyczną ewaluację w MLflow oraz LLM-as-a-judge. Materiały zostały przygotowane i zaktualizowane 24.07.2026.

Notebooki

- 10_exploring_datasets — instrukcje znalezienia, sprawdzenia warunków i ręcznego importu danych Amazon Products od Bright Data oraz Personal Income od Renc z Databricks Marketplace.
- 11_guardrails — przykłady odmowy niebezpiecznych próśb, ograniczenia domenowego i aktualne użycie AI Guardrails zamiast przestarzałego `enable_safety_filter`.
- 12_implementing_guardrails — instrukcja Llama Guard z Marketplace, kategorie unsafe, ocena promptów i integracja z Llama Instruct.
- 13_benchmark_evaluation — porównanie modeli na danych news summarization oraz klasyczna metryka ROUGE-1 w MLflow.
- 14_llm_as_a_judge — własna metryka professionalism 1–5, przykłady EvaluationExample, mean i variance oraz analiza wyników eksperymentu.

Ograniczenia

- Notebook 12 wymaga endpointu Model Serving dla Llama Guard. Free Edition nie pozwoliła utworzyć wymaganego endpointu, więc ten etap nie został zweryfikowany wykonawczo.
- Notebooki 13 i 14 wymagały licznych korekt z powodu zmian MLflow i SDK: legacy API `mlflow.evaluate`, struktury `evaluator_config` oraz różnego formatu odpowiedzi endpointów.

Wnioski

Utworzono dataset news-summarization.csv zawierający 302 pary tekst-referencyjne streszczenie. Moduł pokazuje, że ocena aplikacji generatywnej wymaga danych referencyjnych, jawnej polityki bezpieczeństwa, porównywalnego benchmarku i kontroli jakości odpowiedzi. Parametr `enable_safety_filter` okazał się przestarzały i zwracał błędy, dlatego właściwym kierunkiem są AI Guardrails konfigurowane w ustawieniach endpointu.

5. genai_deploy_and_monitor

Wstęp

Moduł obejmuje batch inference, rejestrację modelu, wdrożenie łańcucha RAG w custom Model Serving oraz monitoring online. Materiały przygotowano 28.07.2026. Notebook 15 może być używany niezależnie, natomiast notebooki 16–17 pozostają niesprawdzone end-to-end.

Notebooki

- 15_batch_inference — tabela Delta z tekstami XSum, pipeline Hugging Face T5-small, MLflow, Unity Catalog Model Registry, alias @champion oraz przykład batch inference przez ai_query.
- 16_deploying_llm_chain — przygotowanie i rejestracja łańcucha RAG, sekrety endpointu, custom Model Serving, instrukcje UI i test inference.
- 17_online_monitoring — rozpakowanie inference payloadów, metryki toxicity, perplexity i readability, Delta streaming oraz Data Quality Monitoring.

Ograniczenia

- Oryginalny kurs zakłada gotowego agenta RAG, ale nie wyjaśnia jego budowy. Odtworzenie takiego agenta z użyciem Codex wymagało oddzielnej i czasochłonnej pracy.
- Dwie próby utworzenia endpointu notebooka 16 zakończyły się niepowodzeniem: provisioning długo pozostawał w stanie Not Ready / Updating, po czym przechodził w Failed.
- AI Gateway telemetry i inference tables nie mogą używać workspace.default, ponieważ jest to default storage. Usługa wymaga katalogu Unity Catalog opartego na external storage. Brak tabeli payload z notebooka 16 blokuje prawdziwy test notebooka 17.
- Cały kurs obejmujący cztery moduły potrzebuje więcej endpointów niż jest dostępnych równocześnie w Free Edition. Kontynuowanie ćwiczeń wymaga usuwania starszych endpointów.

Wnioski

Operacje wdrożeniowe i monitoringowe są długie, a troubleshooting jest mało wygodny: błąd może pojawić się dopiero po wielu minutach. W notebooku batch inference wystąpił też przypadek, w którym wykonanie nie zgłosiło błędu, ale tabela wynikowa zawierała wartości null. Materiały teoretyczne są mało pomocne dla początkujących, ponieważ wprowadzają wiele nazw i definicji bez dostatecznego wyjaśnienia przygotowania zasobów, zależności i częstych punktów awarii.